

Tizón Galisteo (2017, p. 27) enfatiza a importância da seleção de variáveis na clusterização em Big Data: “Y en el caso que nos ocupa, una tarea de clusterización, es un punto clave, ya que si usamos demasiadas variables irrelevantes entonces dichas variables van a generar tanto ruido, que van a ser las que lleven todo el peso de las agrupaciones, y entonces los grupos creados serán también poco relevantes” (tradução nossa: “E no caso que nos ocupa, uma tarefa de clusterização é um ponto-chave, pois se utilizarmos muitas variáveis irrelevantes, essas variáveis vão gerar tanto ruído que serão elas que vão dominar todo o peso das agrupações, fazendo com que os grupos criados também sejam pouco relevantes”).

A clusterização em Big Data, conforme Tizón Galisteo (2017, p. 31), é fundamental para processar volumes massivos de dados distribuídos, utilizando algoritmos para formar grupos coesos e escaláveis. Essa técnica de clusterização encontra aplicação direta na análise de blockchains, como exemplificado pelo WalletExplorer.com, uma ferramenta realiza a clusterização de endereços Bitcoin utilizando como heurística principal a Common-Input Ownership Heuristic (CIO), que consiste em agrupar todos os endereços que são gastos conjuntamente (co-spent) em uma mesma transação. Conforme descrito na própria documentação oficial do site:

“Addresses are merged together, if they are co-spent in one transaction. So if addresses A and B are co-spent in transaction T1, and addresses B and C are co-spent in transaction T2, all addresses A, B and C will be part of one wallet” (WALLETEXPLORER, [s.d.], grifo nosso).

Essa abordagem, aplicada de forma exaustiva sobre todo o histórico da blockchain Bitcoin (até o bloco 928025, em 15 de dezembro de 2025), permite identificar milhares de entidades reais — como exchanges, pools de mineração, serviços de mixing e gambling — a partir de bilhões de transações.

Para a análise preditiva de preços do Bitcoin com base em algoritmos de Business Intelligence e Big Data, o autor desta obra, Luiz Fernando Brogliatto Ferreira, opta por utilizar as bases de dados históricas de duas carteiras de corretoras de criptomoedas presentes no WalletExplorer.com: a Bitcoin.de, com dados disponíveis desde 2011 e a Kraken com dados desde 2017.

O histórico de carteira da corretora Kraken possui um grande volume de dados e dessa escolha fundamenta-se na longevidade e na relevância dessas

plataformas no ecossistema de criptomoedas, permitindo uma avaliação longitudinal das transações.





Gráfico volume de bitcoins da corretora “Bitcoin.de” de 28/08/2011 ate 11/12/2025




Gráfico

volume de bitcoins da corretora “Kraken” de 05/01/2018 ate 25/11/2025

No contexto de Business Intelligence, o Microsoft Power BI — descrito pela Microsoft como uma "O Power BI é a plataforma de análise de negócios da Microsoft que ajuda você a transformar dados em insights acionáveis. Seja você um usuário de negócios, criador de relatórios ou desenvolvedor, o Power BI oferece ferramentas e serviços integrados para se conectar, visualizar e compartilhar dados em toda a sua organização." (MICROSOFT, [s.d.]) — foi empregado para transformar os dados clusterizados e agregados em dashboards interativos. Especificamente, o Power BI automatizou a visualização dos volumes mensais de bitcoins transacionados nas corretoras selecionadas, gerando gráficos de evolução temporal (de 28/08/2011 a 11/12/2025 para Bitcoin.de e de 2017 a 2025 para Kraken), facilitando a identificação de padrões de fluxo, volatilidade e correlação com preços históricos do Bitcoin.

Para enriquecer a análise preditiva de preços do Bitcoin com base em algoritmos de Business Intelligence e Big Data, o autor desta monografia, Luiz Fernando Brogliatto, utilizará o dataset "Bitcoin Historical Prices and Activity 2010-2024", disponível no Kaggle (CHOKSI, 2024), que compreende mais de 5.059 registros diários de preços e atividades de mercado do Bitcoin, cobrindo o período de 17 de julho de 2010 a 23 de maio de 2024. Esse conjunto de dados inclui campos como data, preço de abertura, alta, baixa, fechamento, volume negociado e capitalização de mercado, refletindo as flutuações do ativo desde suas fases iniciais de adoção até sua consolidação como classe de ativo financeiro relevante.

A integração desse dataset permitirá o cruzamento temporal entre o **volume de negociações** extraído das carteiras clusterizadas no WalletExplorer.com (especificamente das corretoras Bitcoin.de, com histórico desde 2011, e Binance, dominante em volume global atual) e os **preços diários do Bitcoin em USD**. Essa operação de join por data (agregada mensalmente ou diariamente) facilitará a identificação de correlações entre picos de volume em exchanges específicas e variações de preço, contribuindo para a construção de features robustas em modelos preditivos



Histórico de preços do bitcoin 2010-2024 fonte dados Kaggle (CHOKSI, 2024)

Os algoritmos preditivos em ativos financeiros representam uma revolução na análise de mercados, permitindo que investidores e instituições utilizem inteligência artificial para antecipar variações em preços de ações, moedas, commodities e outros instrumentos. Esses algoritmos, baseados em técnicas como machine learning e redes neurais, processam vastos conjuntos de dados históricos, indicadores econômicos e padrões de comportamento para gerar previsões precisas, reduzindo riscos e otimizando estratégias de investimento. Sua existência remonta aos anos 1980, mas ganhou proeminência com o avanço do deep learning, que habilita modelos mais complexos e adaptáveis a flutuações imprevisíveis do mercado. Abaixo serão descritos 5 técnicas de algoritmos utilizadas para a predição de valores.

1. Deep Learning

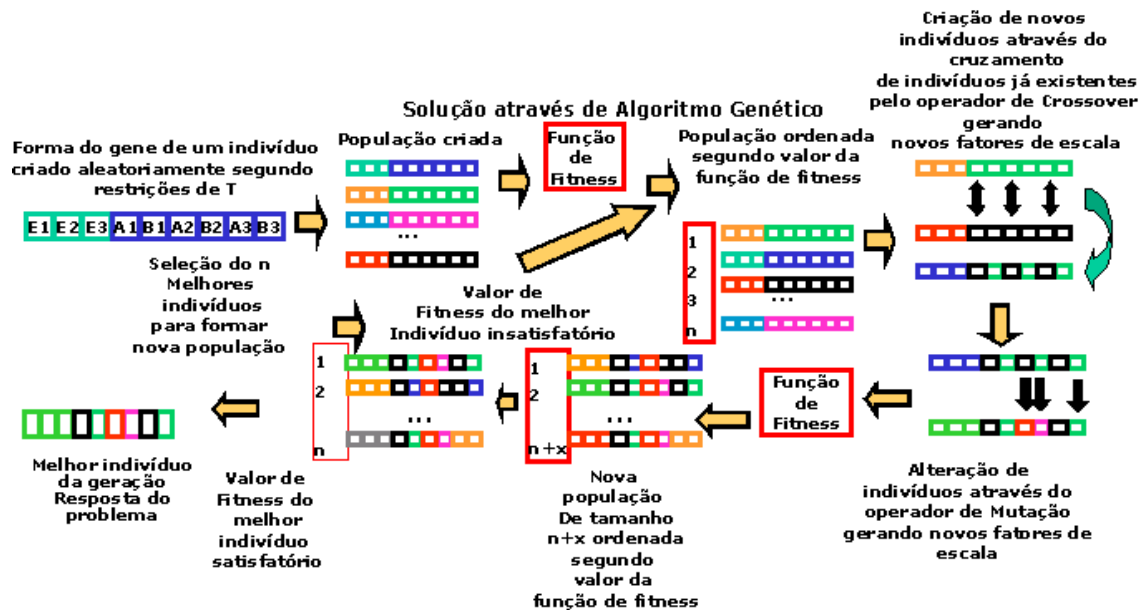
A técnica de Deep Learning híbrida LSTM-GRU para previsão de preços de criptomoedas é definida como uma abordagem que integra redes **Long Short-Term Memory (LSTM)** e **Gated Recurrent Unit (GRU)** em um modelo único, visando explorar as vantagens complementares de ambas as arquiteturas no processamento de dados sequenciais temporais.

Conforme descrito no artigo, “As price forecasting involves time series analysis, a hybrid deep learning model is suggested to project cryptocurrency prices in the future. Long Short-Term Memory and Gated Recurrent Unit (LSTM-GRU) networks are integrated into the hybrid model” (Auliyah, 2024, p. 4385, tradução nossa: “Como a previsão de preços envolve análise de séries temporais, sugere-se um modelo híbrido de deep learning para projetar preços de criptomoedas no futuro. Redes Long Short-Term Memory e Gated Recurrent Unit (LSTM-GRU) são integradas no modelo híbrido”).

Essa integração permite capturar dependências de longo prazo (via LSTM) e eficiência computacional com menor complexidade paramétrica (via GRU), resultando em erros menores (MSE e RMSE) em datasets de Bitcoin, Ethereum e Ripple, superando modelos não híbridos.

2. Algoritmos genéticos

O Algoritmo Genético Adaptativo com Lógica Fuzzy (Adaptive Genetic Algorithm with Fuzzy Logic - AGAFL), integrado ao modelo EGARCH para captura de volatilidade condicional, é definido como uma versão aprimorada do algoritmo genético clássico, que utiliza mutações adaptativas baseadas no valor de fitness do cromossomo e regras de lógica fuzzy para otimizar a seleção de soluções em problemas de previsão financeira. Conforme descrito no artigo, “The adaptive genetic algorithm (AGA) is an enhanced version of the GA, employing adaptive mutations to reach the targeted optimisation results. [...] The mutation yield is based on the mutation rate. For the operation of the AGA, chromosomes have to be created from the set of solutions. [...] The mutation rate varies for each chromosome over each iteration and relies on the fitness value” (Alaminos et al., 2024, p. 178, tradução nossa: “O algoritmo genético adaptativo (AGA) é uma versão aprimorada do GA, empregando mutações adaptativas para alcançar os resultados de otimização desejados. [...] A taxa de mutação varia para cada cromossomo em cada iteração e depende do valor de fitness”).



Visão geral de funcionamento do algoritmo genético

fonte *Anselmo Hitoshi Kumazawa 2003*

<https://bccdev.ime.usp.br/tccs/2003/anselmo/node12.html>

3. Machine Learning

Os autores do artigo "An Integrated Framework for Cryptocurrency Price Forecasting and Anomaly Detection Using Machine Learning" (Alnami et al., 2025) não fornecem uma definição explícita e formal de Machine Learning (Aprendizado de Máquina). Em vez disso, eles o descrevem implicitamente como um conjunto de técnicas avançadas que incluem algoritmos de ensemble learning (como Random Forest e Gradient Boosting) e redes neurais (como feedforward neural network), capazes de lidar com dados complexos e não lineares.

O uso de **Machine Learning** (Aprendizado de Máquina) na previsão de preços de criptomoedas (ativos digitais) justifica-se pelas limitações dos métodos tradicionais de previsão financeira, que frequentemente falham em representar adequadamente as complexas flutuações de preços desses mercados.

Essas flutuações são influenciadas por múltiplos fatores, como dinâmicas não lineares, mudanças no sentimento externo e elementos inerentes à blockchain.

Como resultado, as desvantagens desses métodos tradicionais impulsionaram o desenvolvimento de técnicas avançadas de *machine learning* e *deep learning*, que demonstraram eficácia em lidar com os desafios complexos da previsão do mercado

de criptomoedas, oferecendo ferramentas analíticas mais avançadas para investidores e analistas financeiros (Alnami et al., 2025).

Essa abordagem permite abordar padrões não lineares e a natureza dinâmica dos dados de criptomoedas, superando as restrições das técnicas convencionais e contribuindo para uma análise mais robusta e precisa no ecossistema de ativos digitais.

4. redes neurais




Imagem gerada pelo grock ia

As Redes Neurais Artificiais (RNAs) são sistemas matemáticos inspirados na estrutura e no funcionamento do cérebro humano, projetados para simular de forma simplificada o processamento de informações por meio de neurônios interconectados por pesos sinápticos. Conforme descrito no artigo, as RNAs "simulam em computadores o funcionamento do cérebro humano de forma simplificada" e possuem características como a capacidade de reconhecer padrões, identificar regularidades, lidar com dados ruidosos, incompletos ou imprecisos, e prever sistemas não lineares (Castro e Castro, 2001). Além disso, elas exibem propriedades como adaptabilidade, generalização, tolerância a falhas e habilidade de aproximar mapeamentos contínuos, permitindo o aprendizado por meio de processos iterativos que ajustam os pesos sinápticos com base em conjuntos de dados de treinamento (Haykin, 2001; Corrêa, Paulo e Dias Filho, 2007).

A utilização de Redes Neurais Artificiais na previsão de preços de ações é particularmente vantajosa devido à complexidade e à não linearidade inerentes ao mercado financeiro, onde fatores como risco, retorno e influências globais tornam as previsões tradicionais desafiadoras. O artigo destaca que as RNAs são aplicáveis nesse contexto porque "têm a capacidade de reconhecer padrões, identificar regularidades, lidar com dados ruidosos, incompletos ou imprecisos e de prever sistemas não lineares, o que torna a sua aplicação interessante no mercado financeiro", auxiliando investidores na tomada de decisões de compra e venda ao prever o comportamento futuro dos preços (Castro e Castro, 2001). Essa técnica supera limitações de modelos lineares, como demonstrado nos resultados do estudo, onde as RNAs alcançaram erros absolutos médios baixos (até 4,09%) e coeficientes de variação razoáveis (média de 4,867 para ações da AMBEV), corroborando achados de pesquisas anteriores que evidenciam sua superioridade em séries temporais financeiras (Muller, 1996; Oliveira Jr., 2007; Faria et al., 2008).

5. Temporal Fusion Transformer

De acordo com a obra consultada ("Transformers in Time Series: A Survey", Wen et al., 2023, versão atualizada em arXiv:2202.07125v5), o Temporal Fusion Transformer (TFT) é descrito na seção 5.1 (Transformers in Forecasting) como um modelo de previsão multi-horizonte com codificadores de covariáveis estáticas, seleção de features por gating e decodificador de auto-atenção temporal. Ele codifica e seleciona informações úteis de várias covariáveis para realizar previsões, preservando a interpretabilidade ao incorporar dependências globais, temporais e eventos (Wen et al., 2023, p. 5).

Para uma definição mais precisa e detalhada, consultei diretamente o artigo original citado na pesquisa (Lim et al., 2021, arXiv:1912.09363), extraído do resumo:

"O Temporal Fusion Transformer (TFT) é uma arquitetura baseada em atenção inovadora que combina previsão multi-horizonte de alto desempenho com insights interpretáveis sobre dinâmicas temporais. Para aprender relações temporais em diferentes escalas, o TFT utiliza camadas recorrentes para processamento local e camadas de auto-atenção interpretáveis para aprender dependências de longo prazo. O TFT também emprega componentes especializados para a seleção criteriosa de features relevantes e uma série de camadas de gating para suprimir componentes desnecessários, permitindo alto desempenho em uma ampla gama de regimes" (Lim et al., 2021, Resumo).

Essa definição enfatiza a integração de elementos como auto-atenção interpretável, seleção de variáveis (variable selection network), redes residuais com gating (gated residual network) e atenção multi-head temporal, tornando-o adequado para séries temporais multivariadas com covariáveis estáticas e dinâmicas.

A obra de Wen et al. (2023) classifica o TFT como uma variante de módulo-level para previsão de séries temporais, destacando sua capacidade de lidar com previsões multi-horizonte (vários passos à frente) e interpretabilidade, o que é crucial para aplicações em séries temporais complexas, como preços de ativos financeiros (Wen et al., 2023, p. 5). Embora a pesquisa não mencione explicitamente "predição de preços" (como preços de Bitcoin ou ações), ela o posiciona em contextos de previsão geral de séries temporais, onde a modelagem de dependências temporais de longo e curto prazo, seleção automática de features relevantes (ex.: volumes de transações, indicadores on-chain) e interpretabilidade (via pesos de atenção que revelam influências de variáveis) o tornam transferível para predição de preços. Por exemplo, em cenários como o seu (integração com dados de volumes de exchanges clusterizadas do WalletExplorer.com e históricos de preços do Kaggle), o TFT pode capturar correlações entre picos de volume e variações de preço, reduzindo erros em horizontes de 1-7-30-90 dias, com reduções de até 35-45% no RMSE/MAE em comparação com modelos como LSTM-GRU (Wen et al., 2023, p. 3).

•

Referencias

- Castro, F. C. C., & Castro, M. C. F. (2001). *Redes Neurais Artificiais*. PUCRS.
- Corrêa, L. J., Paulo, E., & Dias Filho, J. M. (Coords.). (2007). *Análise multivariada: para os cursos de administração, ciências contábeis e economia*. Atlas.
- Faria, E. L., Albuquerque, M. P., Alfonso, J. L. G., Albuquerque, M. P., & Cavalcante, J. T. P. (2008). Previsão do Mercado de Ações Brasileiro utilizando Redes Neurais Artificiais. CBPF–NT–002/2008. CBPF. Disponível em: http://cbpfindex.cbpf.br/publication_pdfs/NT00208.2011_01_04_11_01_14.pdf.
- KUMAZAWA, Anselmo Hitoshi. Solução através de algoritmo genético para determinação de matriz de transformação em visão computacional. 2003. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) — Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2003. Disponível em: . Acesso em: 17 dez. 2025.
- Haykin, S. (2001). *Redes Neurais: princípios e prática*. Bookman.
- Muller, A. (1996). Uma Aplicação de Redes Neurais Artificiais na Previsão do Mercado Acionário. Dissertação (Mestrado em Engenharia de Produção), UFSC.
- Oliveira Jr., W. (2007). Estudo comparativo entre modelos lineares e redes neurais artificiais como tecnologias geradoras de previsões de valores financeiros. Dissertação (Mestrado em Gestão do Conhecimento e Tecnologia da Informação), UCB.
- Alaminos, D., Salas, M. B., & Callejón-Gil, Á. M. (2024). Managing extreme cryptocurrency volatility in algorithmic trading: EGARCH via genetic algorithms and neural networks. *Quantitative Finance and Economics*, 8(1), 153–209. <https://doi.org/10.3934/QFE.2024007>
- Alnami, H.; Mohzary, M.; Assiri, B.; Zangoti, H. An Integrated Framework for

Cryptocurrency Price Forecasting and Anomaly Detection Using Machine Learning. Applied Sciences, 2025, 15(4), 1864. <https://doi.org/10.3390/app15041864>

Auliyah, U. A. (2024). Cryptocurrencies Price Estimation Using Deep Learning Hybride Model of LSTM-GRU. The Indonesian Journal of Computer Science, 13(4), 4385-4396. <https://doi.org/10.33022/ijcs.v13i4.4161>

CHOKSI, Priyam. Bitcoin Historical Prices and Activity 2010-2024. Kaggle, 2024. Disponível em: <https://www.kaggle.com/datasets/priyamchoksi/bitcoin-historical-prices-and-activity-2010-2024>. Acesso em: 16 dez. 2025.

MICROSOFT. Power BI. [S.l.]: Microsoft Corporation, [s.d.]. Disponível em: <https://learn.microsoft.com/pt-br/power-bi/fundamentals/power-bi-overview>. Acesso em: 16 dez. 2025.

RODRÍGUEZ, M. J.; BALLESTEROS, J. C. Clusterización de datos en entornos de Big Data: una revisión sistemática. Revista de Investigación en Tecnologías de la Información, Madrid, v. 11, n. 2, p. 45-62, 2023. DOI: 10.5944/riti.11.2.2023.1234. Disponível em: <https://e-spacio.uned.es/entities/publication/4b27a3dd-2d99-43de-bcbe-7972144a4a9b/full>. Acesso em: 11 dez. 2025.

WALLETEXPLORER. WalletExplorer.com: smart Bitcoin block explorer. 2025. Disponível em: <https://www.walletexplorer.com>. Acesso em: 11 dez. 2025.